INSA ROUEN
À taille humaine,
à l'échelle du monde

CC – Istockphotos

**Projet d'Approfondissement et d'Ouverture**

**ASI4 2014-2015**

# Reconnaissance de caractères et détection de langue

## *Rapport de projet*

Manon Ansart
Anthony Courtin

# Table des matières

# Chapitre 1

# Introduction

Le but initial de ce projet était de travailler avec la librairie Olena d'Epita afin de détecter des photos dans des images de documents. Après le téléchargement et la compilation de la librairie, nous avons tenté de la tester et de rechercher les fonctions utiles pour l'application que nous voulions en faire. Nous avons découvert que la librairie était bien plus complexe que ce que nous pensions, et qu'elle ne fournissait pas de fonction permettant de trouver directement une photo dans une image. Nous avons donc décidé de choisir un autre sujet, toujours dans le cadre de la reconnaissance d'image de document. Pendant ce Projet d'Approfondissement et d'Ouverture, nous allons utiliser la bibliothèque ocropus pour reconnaître les caractères à partir d'une image de documents puis en détecter la langue grâce au module de détection de langue cld2 développé par google.

# Chapitre 2

# Compréhension des outils

## 2.1 Ocropus

### 2.1.1 Généralités

OCRopus est un logiciel libre de reconnaissance optique de caractères (ROC) ou optical character recognition (OCR) en anglais. Il a pour but de pouvoir être utilisé à la fois par des chercheurs et des entreprises[**?**], c'est pourquoi il a été développé sous licence Apache 2, qui permet une utilisation commerciale facile.

OCRopus permet d'utiliser plusieurs modules de reconnaissance de texte. En particulier, il implémente Tesseract, qui est considéré comme un des modules les plus exactes dans le domaine des logiciels libres. Ces performances se rapprochent de celles des modules commerciaux peu connus.

### 2.1.2 Fonctionnement

OCRopus, comme n'importe quel logiciel d'OCR, fonctionne selon 5 étapes principales [**?**] : Le pré-traitement, l'analyse de page, la reconnaissance des caractères, le post-traitement puis la mise en forme du résultat

#### Pré-traitement

Cette étape a pour but de traiter l'image d'entrée afin de faciliter les étapes suivantes. Cela implique par exemple de redresser une image inclinée, de travailler sur le contraste... OCRopus fourni une toolbox pour les images en noir et blanc ou niveau de gris.

#### Analyse de page

Une fois l'image optimisée pour le traitement, elle est découpée en lignes de texte. Pour cela, OCRopus recherche d'abord la présence de colonnes, puis découpe chacune de ces colonnes en lignes. Ces lignes pourront ensuite être traitées séparément

#### Reconnaissance de caractère

Les lignes en sortie de l'étape précédente sont analysées afin d'en reconnaître les différents caractères. Pour se faire, les images de caractères sont analysées une à une et comparées par différentes méthodes a des images de caractères connus dans une

base de donné. Le ou les caractères les plus proches sont choisis. C'est dans cette partie que Tesseract est utilisé.

#### Post-traitement

Une analyse statistique est ensuite utilisée pour améliorer le résultat et lever les éventuelles ambiguïtés. Des dictionnaires sont utilisés pour calculer la probabilité de séquences de lettres, ce qui permet de poser un modèle linguistique utilisé dans cette étape.

#### Mise en forme

Les lignes ayant été analysées une par une, une dernière étape est nécessaire afin de mettre en forme les différents résultats obtenus afin d'obtenir une résultat final unique : une page html contenant le texte de sortie. Un script bash nous permet de convertir cet page html en un fichier txt.

### 2.1.3 Résultats

Nous avons tenté d'utiliser OCRopus pour obtenir le texte présent dans différentes images.

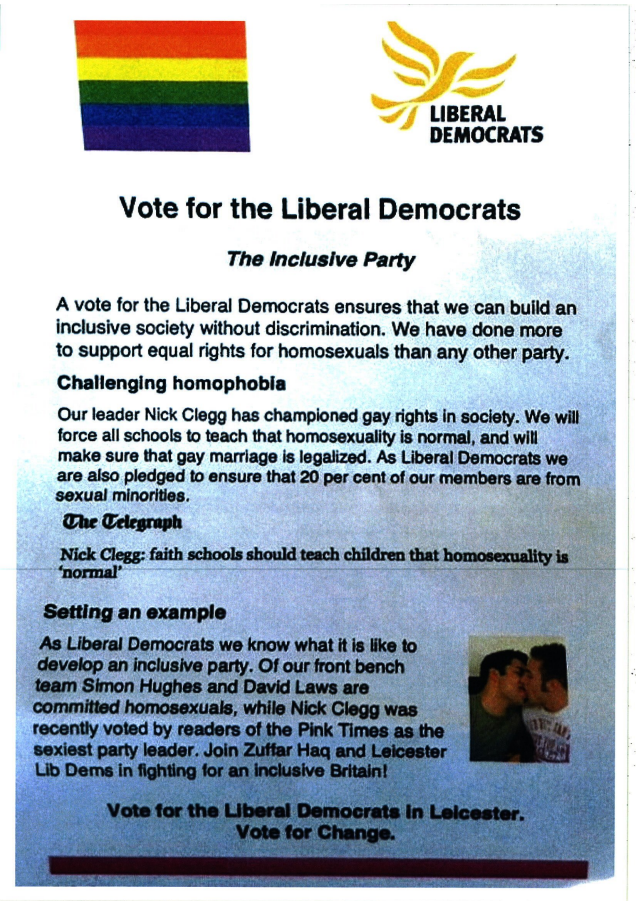


FIGURE 2.1 – Image à traiter par OCRopus

```
--
-.
t,iaeau
DEMOCRAS
Vote for the Llberal Democrats
T7e icluslve Party
Avote for the Liberal Democrats ensures that we can bulld an
inclusive society without discrimination. We have done more
to support equal rights for homosexuals than any other party.
Challenglng homophobla
Our leader Nick Clegg has champloned gay rights in soclety. We wili
force all schools to teach that homosexuallty is normal, and wl
make sure that gay marlage ls legslizad. As Lberal Democrats we
are also pledged to ensure that 20 per cent of our members are from
sexulal minoritles.
tae tCetesraph
Nick Ciegg: faith schools should teach children that homosexuality is
Tomal'
Setting an example
As Llberal Democrats we know what tis ske to
zpy,
team Sion Hughes and Davld Laws are
recently voted by readers of the Pink Tlmes as the
sexiest party leader. Join Zuffar Haq and Leicester
Lib Dems in fighting tor an inclusive Britainl
-r'7
L- -
Vote for thr Lib=P=] f)wmrncrsts In Lelrester.
-
Vc;' y ir ('k -eyrxs,
1
H--
```

FIGURE 2.2 – Texte trouvé par OCRopus

Avec cette image, on remarque que les lettre se ressemblant (i et l) sont souvent confondues, et que la qualité de l'image est importante : le bas de la page, moins bien éclairé, est mal reconnu et le mot "normal", situé sur la pliure, est interprété comme Tomal'. On remarque également que la police est importante : The Telegraph est interprété comme tae tCetesraph.

Des essais sur d'autres images nous ont montré que la rotation est importante (une image tournée à 90 deg n'est pas du tout reconnue par OCRopus) ainsi que l'espacement entre les caractères, qui peut rendre la police plus ou moins "lisible". Enfin, les écritures manuscrites ne sont pas du tout reconnues pas OCRopus.

## 2.2 Cld2

### 2.2.1 Généralités

CLD2, ou Compact Language Detection 2, est un package proposé par google [**?**] pour detecter la langue d'un texte, fourni sous la forme d'une chaine ou d'une page HTML/XML. Comme son nom l'indique, il fait suite à CLD en y ajoutant plusieurs améliorations et des nouveautés, comme des langues supplémentaires (CLD2 peut en detecter 83 différentes, nous ne les listerons pas toutes ici) et la possibilité d'obtenir en sorti le texte correspondant aux 3 langues principales quand plusiquers langues sont detectées, pour pouvoir par exemple tout traduire dans une même langue.

CLD2 a été créé pour travailler sur des pages web comprenant plus de 200 caractères. De ce fait, des "indices", tels que des balises html concernant la langue ou le Top Level Domain de l'URL (.fr, .de ...) sont utilisés pour influencer les résultats du package. Étant donné que nous n'utiliserons pas CLD2 sur des pages web mais sur des chaines de textes extraites par Ocropus, ces indices ne seront pas utilisés dans notre cas.

### 2.2.2 Nettoyage des données

La première étape effectuée par CLD2 afin de travailler sur le texte et détecter la langue est de nettoyer le texte fourni pour pouvoir le traiter.

Tout d'abord, tout le texte est passé en minuscule. Ensuite, tous les nombres, la ponctuation et les tags html, non utiles pour la détections de la langue, sont supprimés. Les mots d'une seule lettre sont également ignorés.

Les mots sont séparés en séquences de 4 lettres, appelés quadrigramme. Le signe _ est ajouté au début ou à la fin du quadrigramme pour indiquer que ce quadrigramme se trouve au début ou à la fin du mot, ce qui peut être caractéristique d'une langue.

Les mots qui ne sont pas caractéristiques d'une langue et pouvant biaiser la detection, tels que les extensions (.jpg, .gif, ...) sont supprimés.

### 2.2.3 Analyse statistique

Une fois les données nettoyées, une analyse statistique peut être effectuée sur le texte afin d'en détecter la langue. On travaillera sur les quadrigramme créé précédemment.

La méthoe utilisée est probabiliste. Une table contenant des entrées de 4 bytes est utilisée afin d'associer à chaque quadrigramme entre 3 et 6 langues les plus probables. Un "score" est alors calculé à partir de la probabilité logarythmique du quadrigramme pour ces langues.

La table contenant les langues et les probabilités a été créée à partir d'un corpus de texte. Dans un premier temps, des pages web en chacune des langues ont été choisies humainement et traitées. 100 milions de pages web choisies automatiquement ont ensuite été ajoutées.

### 2.2.4 Résultats

— "Bonjour, vive notre PAO" : FRENCH(95% 1291p)

— "Nous sommes ravis de vous rencontrer." : FRENCH(97% 885p)

— "Hello, nice to mee you too" : ENGLISH(96% 1175p)

— "Nous sommes ravis de vous rencontrer. Hello, nice to meet you too. " : Unknown(un-reliable). On constate que 2 phrases dans deux langues différentes qui sont bien detectées séparemment ne sont pas bien detectées lorsqu'elles sont ensemble.

— "Nous sommes ravis de vous rencontrer. Visiblement il faut beaucoup plus de texte pour pouvoir detecter la langue. Hello, nice to meet you too." : FRENCH(99% 633p)

— "Nous sommes ravis de vous rencontrer. Visiblement il faut beaucoup plus de texte pour pouvoir detecter la langue. Hello, nice to meet you too. We need to

put a little more text here too. Let's hope it works." : FRENCH(56% 772p), ENGLISH(43% 1314p). Il nous fout plus de texte dans chaque langue quand 2 langues sont mélangées.

— "Il se rague roupète drâle emparouille endosque pratèle libucque barouffle ouillais tocarde marmine manage" : Unknown(un-reliable). En mettant des mots n'existant pas mais à sonorité française (extraits du poème Le Grand Combat d'Henri Michaux), on s'attendrait à ce que CLD2 trouve la langue français mais ce n'est pas le cas. CLD2 n'est pas si facile à berner !

— "Essayons de trouver" : FRENCH(95% 870p). 3 mots français peuvent suffire pour detecter la langue, ce qui est mieux que les 200 mots minimum prévus.

— "esrdtu Essayons eghedu de eedef trouver kjhgvb jjkkl zzza" : FRENCH(98% 300p). L'ajout de séquences de lettres aléatoires ne perturbent pas beaucoup CLD2

— "Essayons de troujver" : Unknown(un-reliable). Le fait de modifier un mot perturbe en revanche beaucoup le résultat.

# Chapitre 3

# Conception de l'application

## 3.1 L'application Android

### 3.1.1 Conception

Nous avons développé cette application pour les systèmes d'exploitation Android. La programmation pour Android est basée sur le langage java que nous avons vu l'année dernière en cours de programmation avancée. Néanmoins, même si nous possédions de bonnes bases java, il nous a fallu plusieurs semaines afin de savoir développer sur Android car celui-ci fonctionne différemment du langage java que nous avions pu voir.

Une fois le langage assimilé, nous nous sommes attaqué à la conception de l'application. Nous avons tout d'abord élaboré un dessin papier des différentes vus de notre application. Au fur et à mesure que nous avancions dans le developpement nous nous sommes rendu compte qu'il serait plus compliqué que prévu de réaliser toutes ces vus. Nous avons donc opté pour une application plus simple mais qui réppond à nos attentes.

la figure ci dessous présente le menu de démarrage de l'application :

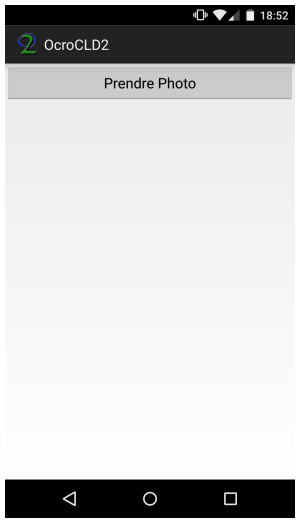


FIGURE 3.1 – Menu principal

### 3.1.2 Installation

Pour installer l'application sur mobile Android il suffit juste de copier ocro-CLD2.apk sur le smartphone. Ensuite, activer l'installation d'applications non certifiées et installer l'application.

### 3.1.3 Fonctionnement

L'intégralité du code de l'application est disponible dans l'archive fournis.

Lorsque nous sommes dans le menu principal il nous suffit d'appuyer sur le bouton "prendre une photo" afin que l'application fasse appelle à l'application appareil photo de notre mobile. Pour faire ceci, nous utilisons un listener qui lorsque l'on clic sur le bouton l'applcation crée un intent afin d'utiliser l'application en charge des photos. Ceci nous à permis de ne pas redévelopper l'appareil photo déjà présent.

Une fois que nous avons pris la photo, il nous suffit de valider et nous retournons à l'accueil. L'application envoie alors grâce à notre classe DataSender l'image par protocole Http sur l'adresse du script php de notre serveur. Une fois cela fait, l'application reste à l'écoute du serveur afin de récupérer la chaine de caractère renvoyée. Cette chaine contient le résultat du traitement par Ocropus puis CLD2.

Nous pouvons alors reprendre une photo ou bien quitter l'application.

### 3.1.4 Tests

Nous avons effectués quelques tests sur notre application dont voici l'un des résultats :

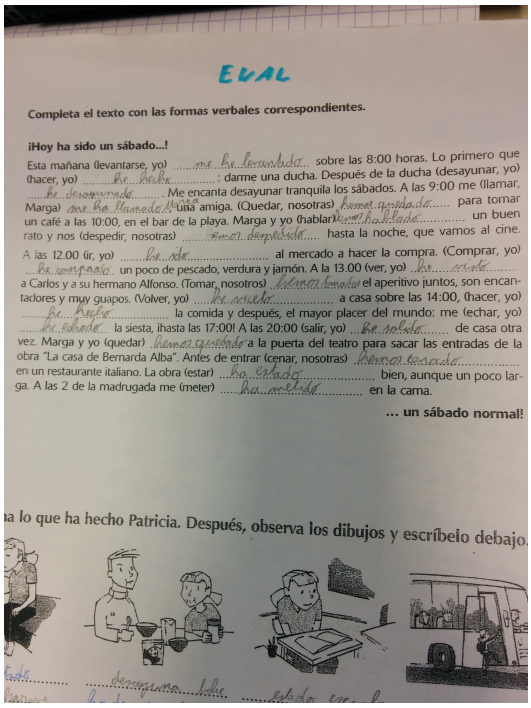

EVAL

Completa el texto con las formas verbales correspondientes.

¡Hoy ha sido un sábado...!

Esta mañana (levantarse, yo) me he levantado sobre las 8:00 horas. Lo primero que (hacer, yo) he hecho: darme una ducha. Después de la ducha (desayunar, yo) he desayunado. Me encanta desayunar tranquila los sábados. A las 9:00 me (llamar, Marga) me ha llamado una amiga. (Quedar, nosotras) hemos quedado para tomar un café a las 10:00, en el bar de la playa. Marga y yo (hablar) hemos hablado un buen rato y nos (despedir, nosotras) hemos despedido hasta la noche, que vamos al cine. A las 12.00 (ir, yo) he ido al mercado a hacer la compra. (Comprar, yo) he comprado un poco de pescado, verdura y jamón. A la 13.00 (ver, yo) he visto a Carlos y a su hermano Alfonso. (Tomar, nosotros) hemos tomado el aperitivo juntos, son encantadores y muy guapos. (Volver, yo) he vuelto a casa sobre las 14:00, (hacer, yo) he hecho la comida y después, el mayor placer del mundo: me (echar, yo) he echado la siesta, ¡hasta las 17:00! A las 20:00 (salir, yo) he salido de casa otra vez. Marga y yo (quedar) hemos quedado a la puerta del teatro para sacar las entradas de la obra "La casa de Bernarda Alba". Antes de entrar (cenar, nosotras) hemos cenado en un restaurante italiano. La obra (estar) ha estado bien, aunque un poco larga. A las 2 de la madrugada me (meter) he metido en la cama.

... un sábado normal!

...a lo que ha hecho Patricia. Después, observa los dibujos y escríbelo debajo.

FIGURE 3.2 – Document en espagnol pris en photo


FIGURE 3.3 – Menu principal

Nous pouvons voir que l'image a bien été traitée par le serveur et que la langue renvoyée par CLD2 est la bonne.

### 3.1.5 Problèmes rencontrés

Tout d'abord, l'apprentissage du java pour Android est apparu plus difficile que prévu car nous ne pensions pas qu'il y avait autant de différences. De plus nous avons eu quelques soucis pour installer le SDK android sur Eclipse. C'est pourquoi nous avons pris un peu de retard au début de ce projet.

Ensuite, il a été assez compliqué de faire communiquer l'application avec le serveur. Plus précisément, nous ne savions pas quel type de protocole était le plus adapté afin d'envoyer une photo sur un serveur. Après avoir consulté Mr Nicolas Malandin, nous avons donc opté pour le protocole Http.

Finalement, nous avons toujours des problèmes de réponse du serveur, ce qui fait que par moment nous ne sommes pas certain de recevoir une réponse. En effet, le traitement de l'image par Ocropus prend plusieurs minutes suivant la taille du texte à traiter.

## 3.2 La communication avec le serveur

### 3.2.1 Connection au serveur

Afin d'installer et de faire nos tests nous nous connectons en ssh sur un serveur que Mr Sebastion Bonnegent nous a mit à disposition : *ssh -X paoandroid@asi-android.insa-rouen.fr*. De plus il faut se trouver sur le réseau WEP-26 de l'INSA de Rouen pour pouvoir se connecter. Lorsque le PAO sera terminer le serveur sera fermé, il faudra donc redemander un serveur pour pouvoir reprendre le projet.

### 3.2.2 Installation des outils

#### Ocropus

- Dans un premier temps il faut cloner le répertoire d'Ocropus à l'aide de la commande : *hg clone -r ocropus-0.7 https ://code.google.com/p/ocropus* ;
- Si cela ne fonctionne pas il faut installer le package que linux vous suggère ;
- Ensuite déplacez vous dans le dossier ocropy : *cd ocropus/ocropy* ;
- Installez les packages necessaires au fonctionnement : *sudo apt-get install $(cat PACKAGES)* ;
- Téléchargez les modèles python : *python setup.py download_models* ;
- Lancez l'installation : *sudo python setup.py install* ;
- Lancez les tests : *./run-test* ;
- Si tout est correctement installé vous devriez avoir un message d'Ocropus disant que vous pouvez visualiser les résultats en tapant une certaine ligne de commande.

#### CLD2

- Allez dans votre dossier tmp : *cd /tmp/* ;
- Téléchargez le répertoire de CLD2 : *svn checkout http ://cld2.googlecode.com/svn/trunk/cld2* ;
- Déplacez vous dans le dossier internal : *cd cld2/internal* ;
- Copiez et collez le fichier compile_libs_32bit.sh dans le répertoire internal (ce fichier est joint dans l'archive que nous avons fourni). Celui-ci sert à pouvoir exécuter CLD2 dans un terminal ;
- Autorisez l'exécution de ce fichier : *chmod u+x compile_libs_32bit.sh* ;
- Exécutez le fichier : *./compile_libs_32bit.sh* ;
- Effectuez le test suivant dans votre terminal : *echo "Hello World je suis gentil trop bien my name is i don't know" | cld2* ;
- Si tout est correctement installé votre terminal affichera un message vous diasnt que les texte est en anglais et français.

#### Lynx

Il faut installer lynx qui permet de convertir une page html en fichier txt : *sudo apt-get install lynx*.

### 3.2.3 PHP

Comme dit précedemment l'application envoie l'image au serveur par protocole Http directement sur un script php qui, lorsqu'il reçoit l'image, la copie dans le bon dossier et lance les différentes commandes nécessaire au traitement de l'image. Ce script est disponible dans l'archive fourni. Une fois que Ocropus a fini CLD2 est exécuté et renvoi une chaine de caractère transmise à l'application par protocole Http.

### 3.2.4 Problèmes rencontrés

Le premier problème que nous avons rencontrés avec le serveur vient d'Ocropus. En effet, lorsque celui-ci est exécuté, il ouvre une fenêtre graphique afin de traiter les images. Celle-ci n'est pas visible à l'écran mais empêche le bon fonctionnement d'Ocropus, d'où le -X dans la commande permettant de se connecter au serveur qui permet de se servir de notre écran comme écran miroir.
Afin de résoudre ce problème nous avons modifier quelques lignes de code des bibliothèques d'Ocropus afin que celui-ci n'ouvre plus de fenêtre graphique pour exécuter le script bash directement grâce à une requête HTML et ne plus avoir de message d'erreur. Afin de savoir quel fichier modifer il faut se connecter au serveur sans le -X et executer Ocropus.
Voici les trois lignes de code à rajouter au tout début du fichier :

— import matplotlib

— matplotlib.use('Agg')

— import matplotlib.pyplot

Si le problème persiste après c'est que vous n'avez pas modifié le bon fichier python.

Le deuxième problème fut les droits d'accès aux fichier. En effet, lorsque l'application android envoie la requête sur le script php du serveur, ce script est exécuté par Apache. Il faut donc que Apache possède les droits d'accès, de modification et d'exécution sur les dossiers d'Ocropus et tous ceux nécessaire au bon fonctionnement du script.
Pour résoudre ce problème nous avons donnés les droits root à Apache ce qui ne constitue pas forcément la meilleure des solutions car très risquée. Néanmoins, vu que cette application est déstinée uniquement à être utilisée dans le cadre du PAO cela nous a semblé être la solution la plus simple et rapide.

# Chapitre 4

# Conclusion